

Лабораторная работа №2

Задача классификации

Dataset: Abalone

Цель

Создать модель для бинарной классификации
возраста моллюсков

Молодые (≤ 10 лет) vs Взрослые (> 10 лет)

Исходные данные

Датасет: Физические характеристики морских моллюсков Abalone

- 4176 наблюдений
- 8 исходных признаков + пол (категориальный)

Признаки:

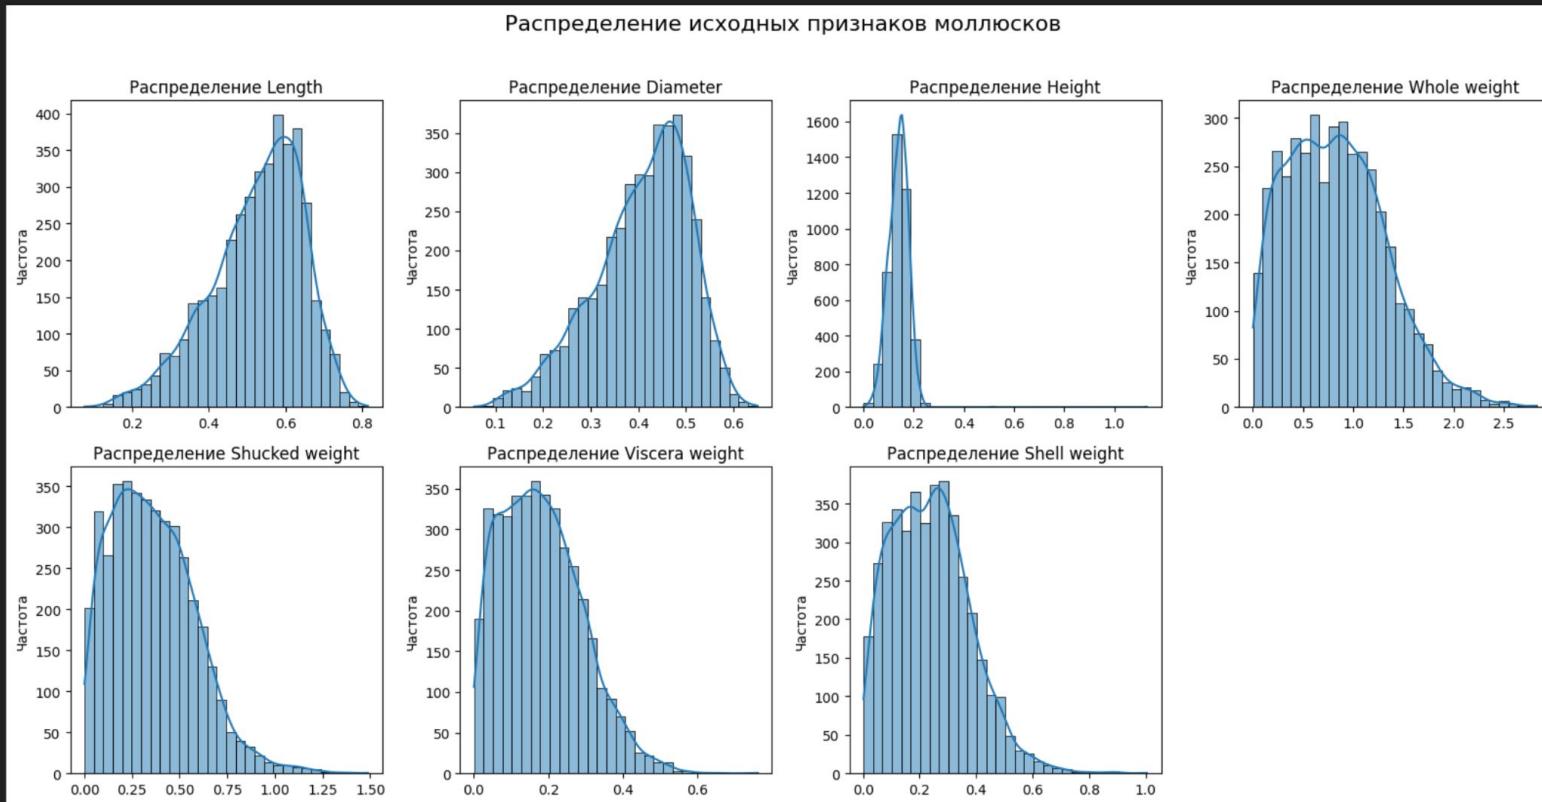
- Длина, диаметр, высота
- Веса: общий, без раковины, внутренностей, раковины
- Количество колец (целевая переменная для регрессии)

Подготовка данных

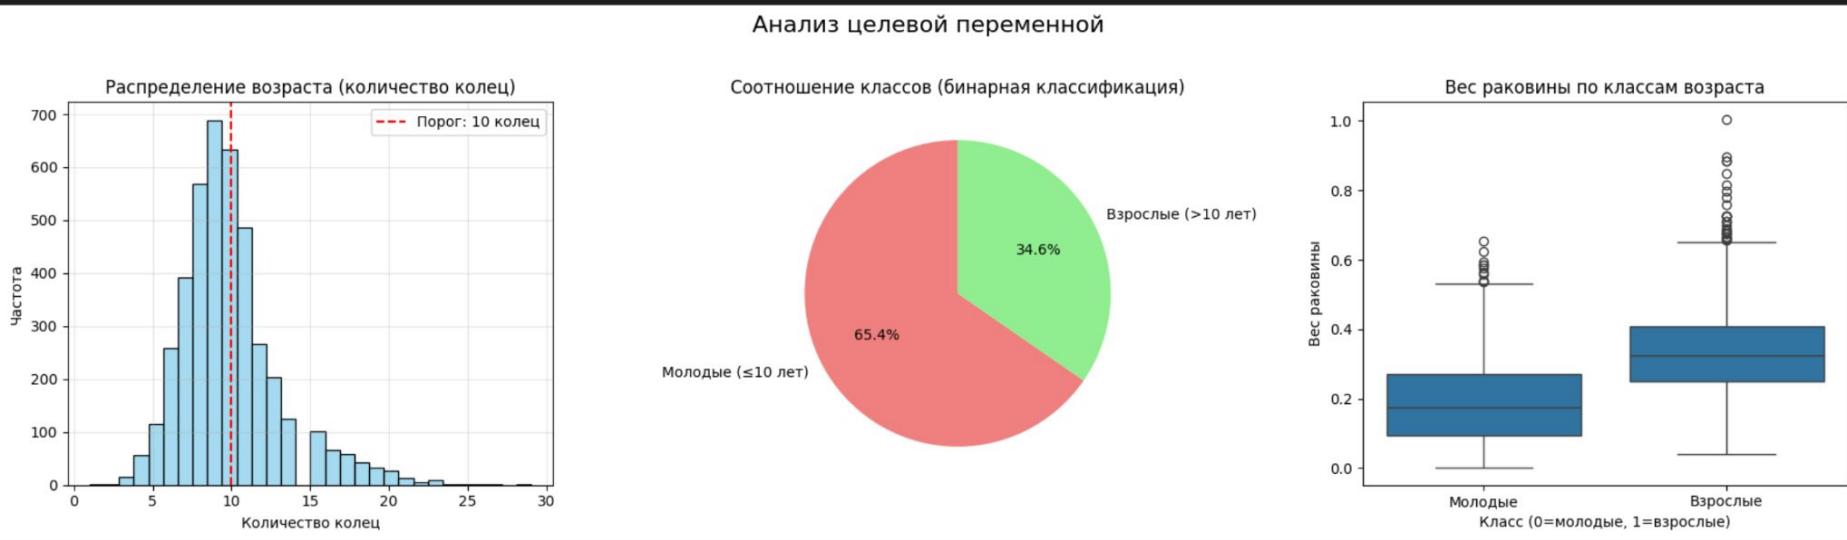
Создание новых признаков для улучшения
качества модели:

1. share_of_meat – доля мяса от общего веса
2. share_of_shell – доля раковины
3. volume_approx – приблизительный объем
4. density – плотность моллюска
5. weight_per_ring – вес на одно кольцо

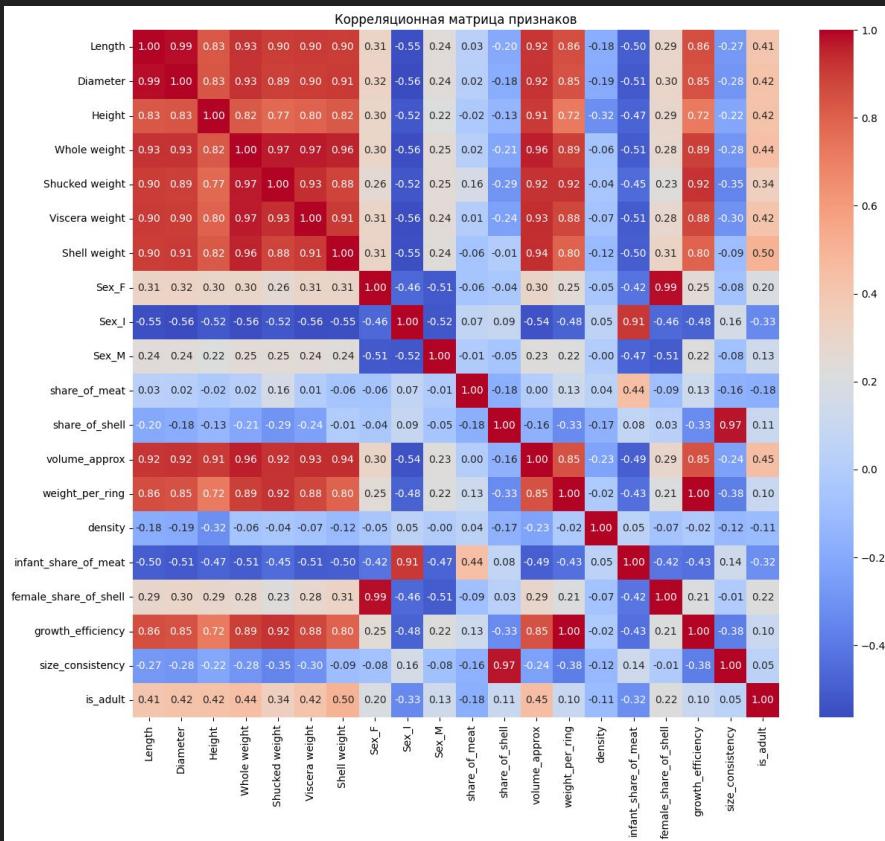
Визуализация распределения признаков



Визуализация распределения целевой переменной



Корреляционная матрица



Выбор модели – Градиентный бустинг

Gradient Boosted Decision Trees

$$\hat{y}_i^1 = f_1(x_i)$$



$$\hat{y}_i^2 = \hat{y}_i^1 + f_2(x_i)$$



$$\hat{y}_i^M = \hat{y}_i^{M-1} + f_M(x_i)$$

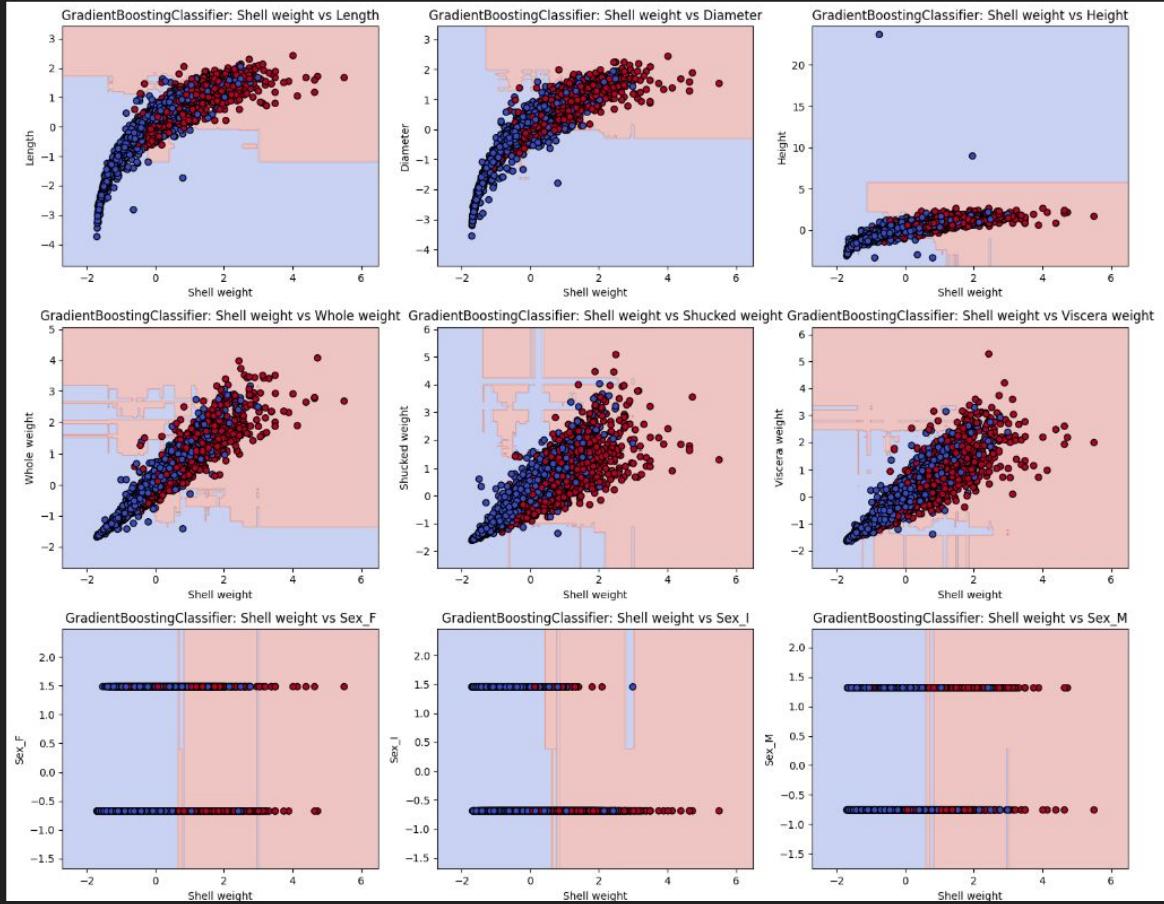


$$f_1(x_i) \rightarrow y_i$$

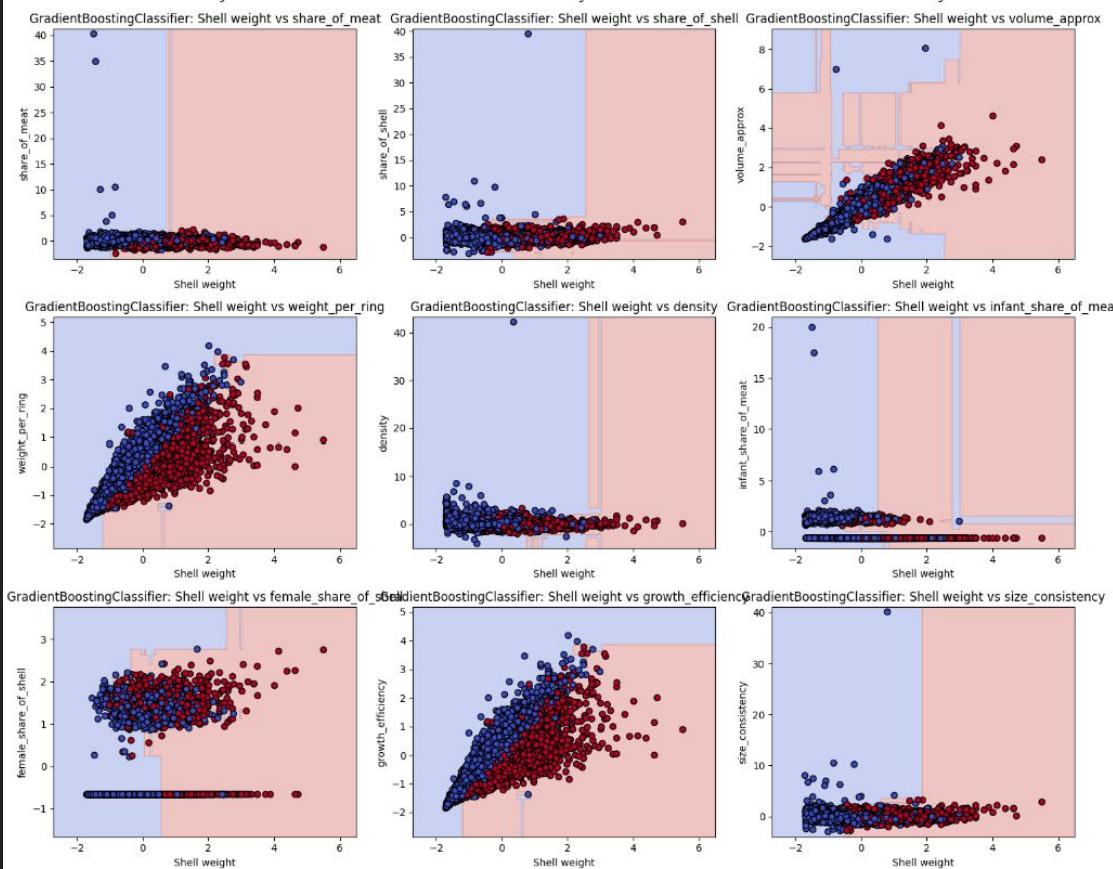
$$f_2(x_i) \rightarrow y_i - \hat{y}_i^1$$

$$f_M(x_i) \rightarrow y_i - \hat{y}_i^{M-1}$$

Графическое представление решения



Графическое представление решения



Результаты обучения и сравнение

==== Boosting ===

Accuracy: 0.967 ± 0.001
F1-score: 0.951 ± 0.002
ROC-AUC: 0.994 ± 0.002

==== XGBoost ===

Accuracy: 0.968 ± 0.006
F1-score: 0.952 ± 0.010
ROC-AUC: 0.994 ± 0.001

==== SVM ===

Accuracy: 0.959 ± 0.006
F1-score: 0.936 ± 0.010
ROC-AUC: 0.996 ± 0.002

==== Logistic Regression ===

Accuracy: 0.954 ± 0.006
F1-score: 0.930 ± 0.010
ROC-AUC: 0.987 ± 0.003

==== KNN ===

Accuracy: 0.872 ± 0.004
F1-score: 0.799 ± 0.008
ROC-AUC: 0.926 ± 0.008

==== DesicionTree ===

Accuracy: 0.949 ± 0.005
F1-score: 0.925 ± 0.008
ROC-AUC: 0.941 ± 0.008

==== RandomForest ===

Accuracy: 0.964 ± 0.003
F1-score: 0.947 ± 0.005
ROC-AUC: 0.993 ± 0.001